

OrganChip Insight

Un espace de microscopie traçable pour les expériences sur puce

OUTIL & PLATEFORME | AI4S OPEN INNOVATION 2026

Une analyse d'images gouvernée par les preuves, qui conserve les sources, overlays, mesures, provenance, incertitudes et résultats négatifs dans une expérience locale reproductible.

Date du candidat	17 septembre 2026
Équipe	Équipe solo ; nom public de l'auteur à confirmer
Release	Validée sur dev ; tag public en attente d'autorisation
Périmètre scientifique	Exploration microscopique non clinique

PDF candidat. Apache-2.0 est fixée pour le code ; le nom public de l'auteur, le tag de release et les URL publiques restent à confirmer.

Résumé

La microscopie d'organes sur puce produit des images longitudinales précieuses, mais un résultat d'analyse est difficile à croire ou à réutiliser lorsque les métadonnées d'acquisition, l'identité de l'algorithme, le coût de calcul et les limites scientifiques sont séparés de la sortie. OrganChip Insight est un outil et une plateforme locale et reproductible qui réunit la gestion d'expériences, l'import robuste d'images, la segmentation CPU, l'inspection des overlays, les mesures par image, l'export des résultats et un registre transparent des moteurs. Le moteur adaptatif par défaut ne requiert aucun poids appris et fonctionne hors ligne. Les benchmarks externes BBBC019 et BBBC038 sont produits par des scripts versionnés et présentés dans le produit avec l'incertitude, le temps d'exécution, la mémoire, les décisions de promotion et la provenance SHA-256.

La crédibilité fait partie de l'implémentation, et non d'une annexe. L'étude de classification de qualité des images d'organes sur puce emploie des splits groupés, des contrats d'exécution verrouillés, des comparateurs fondés uniquement sur les métadonnées, des métriques par mode et des ablations pré-enregistrées. Aucune configuration n'a démontré un signal de qualité robuste et indépendant des métadonnées d'acquisition et de culture ; le split de test gelé n'a donc jamais été ouvert. Le CNN retenu est limité à un démonstrateur ONNX optionnel qui s'abstient toujours et ne produit jamais de décision automatique bon/mauvais. De même, l'interface indique des composantes connexes plutôt que des cellules, car aucune annotation d'instances ne valide le comptage sur les images du concours.

Le système obtenu n'est pas un dispositif de diagnostic. C'est un workflow local et auditable d'exploration microscopique attentive à la qualité, conçu pour préserver la relation entre images, mesures, métadonnées, incertitude et résultats négatifs.

1. Problème et utilisateur cible

Les expériences bright-field sur organes sur puce produisent souvent des images répétées selon les dispositifs, lignées, jours de culture et modes d'acquisition. Un laboratoire a besoin de plus qu'un modèle de segmentation isolé. L'unité utile est une expérience qui conserve le contexte, valide les fichiers entrants, préserve les images brutes, rattache chaque sortie à une version du moteur et exporte des preuves révisables en dehors de l'application.

L'utilisateur cible est un laboratoire de recherche travaillant sur des images non cliniques d'organes sur puce. Le workflow principal est le suivant :

- 1 créer une expérience nommée et enregistrer les métadonnées disponibles ;
- 2 importer un lot d'images et inspecter les fichiers acceptés et rejetés ;
- 3 exécuter un moteur d'analyse déclaré ;
- 4 examiner les overlays et les mesures par image ;
- 5 exporter des preuves structurées pour une analyse ou un audit ultérieur.

OrganChip Insight ne revendique ni diagnostic, ni recommandation thérapeutique, ni prédiction de toxicité ou d'efficacité, ni comptage cellulaire validé.

2. Données, provenance et base juridique

2.1 Jeux de données

Jeu de données	Version et licence	Usage dans le projet	Traçabilité
OOC Image Dataset, Zenodo 10203721	version 2023, CC-BY-4.0	étude groupée de classification de qualité	manifestes train/validation/test verrouillés et checksums
BBBC019 Microfluidics	v2, CC-BY-3.0	benchmark externe de segmentation du premier plan	manifeste, CSV par image et rapport JSON
BBBC038 stage 1 train	v1, CC0-1.0	benchmark borné d'instances et de comptage sur 12 images	hashes de l'archive, des images et des masques ; manifeste verrouillé

La déclaration complète des données est maintenue dans [docs/declaration-ia-et-licences.md](#). Aucune donnée personnelle, clinique ou privée n'est utilisée.

2.2 Pourquoi trois jeux de données ne forment pas une seule validation

Les jeux répondent à des questions différentes. BBBC019 fournit des masques binaires de premier plan pour un petit ensemble microfluidique DIC. BBBC038 fournit des masques d'instances nucléaires qui permettent d'auditer la détection d'instances et le comptage. Le jeu OOC du concours fournit des étiquettes de qualité au niveau image, mais aucun masque d'instance. Les scores sont donc présentés par jeu et par tâche. Ils ne sont jamais fusionnés en un chiffre unique, et BBBC019 ou BBBC038 ne valide pas le comptage cellulaire sur les images OOC.

2.3 Dépendance longitudinale et conception du split

La structure des noms et acquisitions a révélé que des dates adjacentes et des lignées communes pouvaient traverser un split naïf. L'audit des campagnes a identifié 29 campagnes de trois jours et 270 images de test exposées à une date voisine avec leur propre lignée dans l'ancien split. Il s'agit d'un risque de dépendance longitudinale, et non d'une preuve que deux images viennent de la même puce physique. Un manifeste v2 conscient des campagnes a donc été pré-enregistré et généré, tandis que le split v1 a été conservé. Les détails figurent dans [docs/protocole-campagnes-v2.md](#) et [reports/ooc-campaign-split-v2.json](#).

La formulation honnête reste la suivante : le split est groupé par date d'acquisition et contrôlé pour les quasi-doublons détectés, mais l'indépendance biologique n'est pas établie faute d'identifiants de puce et de puits.

3. Architecture du système




Figure 1. Architecture locale et rôles des moteurs selon les preuves.

La plateforme adopte volontairement une architecture locale réduite :

```

text
Interface React + TypeScript
  |
  v
Application FastAPI ---- OpenAPI et CLI
  |
  +---- SQLite : expériences, images, résultats
  +---- système de fichiers : uploads et overlays
  +---- registre de moteurs
        +---- segmentation adaptative v1
        +---- démonstrateur ONNX optionnel du run B
        +---- candidats de benchmark isolés
  
```

Docker Compose regroupe le frontend, Nginx, le backend et le volume persistant. Nginx et l'API appliquent des contraintes cohérentes de taille et de sécurité. Les conteneurs utilisent des comptes non root. Les dépendances Python et JavaScript exactes sont verrouillées dans **backend/uv.lock** et **frontend/package-lock.json**.

4. Méthode produit

4.1 Import robuste

Le backend décode les formats PNG, JPEG et TIFF au lieu de se fier aux extensions. Il borne la taille et le nombre total de pixels, détecte les doublons binaires et prend en charge les TIFF 16 bits en niveaux de gris. L'entrée de mesure est normalisée par percentiles robustes, tandis que le fichier original est préservé. L'import et l'analyse sont deux opérations séparées, ce qui empêche un échec d'analyse de dupliquer les images lors d'une nouvelle tentative.

4.2 Segmentation adaptative

Le moteur par défaut utilise un seuillage classique et de la morphologie, suivis d'une analyse des composantes connexes. Il n'a aucun poids externe et fonctionne sur CPU. Les sorties comprennent l'overlay de segmentation, la fraction de premier plan, le nombre de composantes, les résumés de surface, le diamètre estimé en pixels, l'intensité, le contraste et un indice de contraste relatif.

Ces sorties sont des heuristiques exploratoires. Une composante connexe peut en particulier regrouper plusieurs cellules ou représenter un débris, une texture de fond ou une autre structure. L'interface et les exports conservent le terme « composante connexe ».

4.3 Registre des moteurs et CNN expérimental

Chaque moteur déclare son statut, sa disponibilité, son rôle et ses limites. Le modèle MobileNetV3 du run B ne peut être activé qu'avec un bundle ONNX local dont les hashes du modèle, du prétraitement et du rapport de sélection correspondent aux valeurs déclarées. Il redimensionne une entrée en niveaux de gris à 448 pixels selon le contrat de prétraitement exporté.

Chaque sortie CNN porte le statut « À vérifier ». Le softmax est explicitement étiqueté comme non calibré, le mode d'acquisition et les hashes de provenance sont affichés, et aucune conclusion automatique bon/mauvais, aucun overlay de segmentation et aucun comptage ne sont attachés. Sans ONNX Runtime ou sans le bundle exact, le moteur reste visible mais indisponible, tandis que le workflow adaptatif continue de fonctionner.

5. Conception de l'évaluation

5.1 Benchmarks externes de segmentation et d'instances

Les scripts BBBC019 calculent F1 et IoU du premier plan par image, bootstrapent les macro-métriques, enregistrent le temps et la mémoire du processus et génèrent des overlays d'erreur. Les rapports adaptatif et μ SAM couvrent les mêmes 13 images.

Le protocole BBBC038 a été committé avant l'exécution. Il fixe un sous-ensemble déterministe de 12 images, μ SAM **vit_b_lm** avec génération automatique de prompts, le F1 objet aux IoU 0,50 et 0,75, l'erreur absolue médiane en pourcentage du comptage et trois critères de promotion. Aucun réglage postérieur au résultat n'a été effectué. Voir [docs/protocole-bbbc038-instances-v1.md](#).

5.2 Classification de qualité

La cible de classification est binaire : **good/bad**. Le jour de culture et la lignée sont des covariables et des comparateurs, pas des cibles. La validation a été rapportée globalement et par mode d'acquisition, résolution, lignée et jour.

Le workflow sépare smoke tests, validation et évaluation finale. Le runtime, le bundle source, les poids ImageNet, les manifestes de split, les checkpoints et les archives de résultats sont identifiés par hashes. Un modèle couleur de référence à 224 pixels et deux ablations pré-enregistrées ont été évalués : gris à 224 pixels (A) et gris à 448 pixels (B). Une troisième ablation de recadrage était conditionnelle et n'a pas été lancée, car le critère RGB pré-enregistré n'était pas atteint. Le jeu de test gelé n'a jamais été ouvert.

Des règles fondées uniquement sur les métadonnées ont été ajustées sur le train et évaluées sur la validation afin de mesurer la force des raccourcis. Un CNN globalement fort peut en effet échouer au sein d'un mode d'acquisition.

6. Résultats

6.1 Segmentation du premier plan sur BBBC019




Figure 2. Macro-scores BBBC019 ; le meilleur résultat μSAM a un coût mesuré nettement supérieur.

Moteur	Macro-F1	Intervalle bootstrap à 95 %	Macro-IoU	Temps CPU moyen/image	Mémoire maximale
Segmentation adaptative v1	0.424892	[0.369769, 0.467653]	0.273632	0.112333 s	324.668 MB
μSAM vit_b_lm APG	0.815542	[0.758206, 0.861862]	0.698535	42.843791 s	8702.957 MB

Rapports sources : [JSON adaptatif](#) et [JSON μSAM](#).

μSAM est plus précis sur cette petite tâche externe de premier plan, mais il est environ 381 fois plus lent par image dans les environnements mesurés et utilise nettement plus de mémoire. Les ratios de temps dépendent de l'environnement et ne constituent pas une propriété générale indépendante du matériel.

6.2 Audit d'instances sur BBBC038

Métrique	Résultat
Macro-F1 objet à IoU 0,50	0.628327
Macro-F1 objet à IoU 0,75	0.481698
Erreur absolue médiane de comptage	15.3409%
Temps CPU moyen/image	36.690719 s
Mémoire maximale du processus	8896.457 MB

Le rapport source est [bbbc038-stage1-subset-v1-microsam-vit-b-lm-apg.json](#). Deux des trois critères de promotion pré-enregistrés ont échoué. μ SAM n'a pas été promu dans le produit et aucun réglage n'a été effectué après observation du résultat.

6.3 Classification de qualité et raccourcis de métadonnées



Figure 3. La validation par mode révèle le signal RGB faible et instable masqué par les scores globaux.

Run	BA globale	BA L	BA RGB	AUC globale	AUC L	AUC RGB
Référence couleur 224	0.7619	0.7729	0.6315	0.7996	0.8521	0.6309
A : gris 224	0.6704	0.7389	0.5948	0.7176	0.7529	0.5848
B : gris 448	0.7750	0.8338	0.6079	0.8414	0.8551	0.6985
Métadonnées : mode × classe de jour	0.7920	0.8171	0.6533	-	0.8171	0.7068

Les valeurs du comparateur de métadonnées exigent une importante analyse de sensibilité. En RGB, sa balanced accuracy de 0,6533 provient entièrement de la distinction entre les étiquettes publiées **4_days** et **4+_days** ; leur fusion réduit la balanced accuracy RGB à 0,5000 et la balanced accuracy globale à 0,7413. Ce comparateur met en évidence la structure du jeu et l'identification des campagnes ; ce n'est pas un modèle de qualité déployable.

Pour le run B, la différence bootstrap avec la référence en RGB contient zéro, et la sélection de seuil leave-one-date-out est instable. L'analyse post hoc au sein des strates ne trouve qu'un résidu RGB modeste dans l'échantillon et ne peut pas le séparer des effets de sélection de modèle. Les preuves et corrections complètes figurent dans le [contre-audit de classification](#) et le [rapport versionné des comparateurs](#).

Conclusion scientifique figée : « Sur cette validation, aucun signal de qualité robuste et indépendant des métadonnées d'acquisition et de culture n'est démontré ; le résidu observé en RGB pour le run B est modeste, mesuré en échantillon et non distinguable d'un effet de sélection. »

L'étude de classification est donc close, aucune configuration n'est éligible et le jeu de test gelé reste fermé.

7. Vérification du produit

La suite backend contient 177 tests collectés dans le candidat du 17 septembre 2026 : 176 réussissent et un test dépendant de l'environnement est ignoré. Ruff, le type-check TypeScript, le build Vite de production, la synchronisation des notebooks, celle du résumé de benchmarks, l'audit de l'arbre de release, l'inventaire de checksums et la configuration Docker Compose passent via **make check**.

Playwright démarre des projets Docker isolés avec des volumes neufs. Le parcours rapide crée une expérience, importe une image synthétique, exécute l'inférence adaptative, vérifie l'overlay et la réserve scientifique, puis télécharge JSON et CSV. Un second parcours importe trois images publiques verrouillées par hash (OoC RGB, OoC en niveaux de gris et TIFF BBBC019), vérifie les métadonnées du format source, exécute le même workflow et confirme que tous les hashes des sources restent inchangés. Des barrières supplémentaires rapportent zéro violation Axe, vérifient le focus clavier visible, le reflow mobile à 390 px, une largeur effective à 200 %, ainsi que la persistance des sources, résultats, exports, galerie et visionneuse après redémarrage des deux conteneurs.

Le candidat a également été reconstruit avec **docker compose build --pull --no-cache**. L'audit de release n'a trouvé aucun secret suivi, chemin personnel, cache, jeu brut ni binaire de modèle non distribuable. L'inventaire SHA-256 couvre 40 rapports, manifestes, notebooks, sources de soumission et preuves frontend suivis.

8. Crédibilité et limites

- 1 **Groupement biologique.** La date d'acquisition est un proxy, pas un identifiant de puce ou de puits. L'indépendance biologique ne peut pas être établie.
- 2 **Étiquettes de qualité.** Des images adjacentes ou quasi dupliquées peuvent porter des étiquettes contradictoires. Le projet ne les réinterprète pas après observation des sorties.
- 3 **Raccourcis d'acquisition.** La résolution identifie presque le mode et le mode interagit fortement avec la prévalence des classes. Les métriques globales sont insuffisantes.
- 4 **Petits benchmarks externes.** BBBC019 ne contient que 13 images évaluées et BBBC038 un audit pré-enregistré de 12 images. Aucun résultat n'est une estimation de population sur les images OOC.
- 5 **Aucune calibration physique.** Les surfaces et diamètres sont en pixels, pas en μm ou μm^2 .
- 6 **Aucun comptage cellulaire validé.** Les composantes connexes sont des structures heuristiques, pas des cellules ou noyaux vérifiés sur OOC.
- 7 **Sortie CNN non calibrée.** Les valeurs softmax du démonstrateur optionnel ne sont pas des probabilités calibrées et ne pilotent aucune décision automatique.
- 8 **Périmètre de déploiement.** SQLite et les fichiers locaux conviennent à un prototype local ou une instance unique, pas à un système clinique multi-tenant.

9. Valeur pratique

La valeur immédiate de la plateforme est la discipline du workflow : images, métadonnées, identité du moteur, overlays, mesures, exports et limites coexistent dans une expérience. Un laboratoire peut comprendre pourquoi une image a été rejetée, relancer une analyse sans réimporter, comparer les preuves des moteurs et exporter un dossier révisable sans service externe.

Le résultat CNN négatif est également utile opérationnellement. Il empêche un classifieur dominé par les raccourcis de devenir une barrière automatique et identifie les métadonnées nécessaires aux futurs jeux : vocabulaire stable des jours, identifiants de puce et de puits, types d'artefacts explicites, calibration physique et au moins cinq dates indépendantes par mode.

Les recherches futures pourront étudier un score d'écart à la maturation conditionné par mode, jour et lignée, des objectifs auxiliaires adversariaux pour le jour de culture, des annotations expertes d'artefacts et l'interopérabilité OME-Zarr. Ce sont des perspectives, pas des fonctionnalités de la soumission.

10. Reproduction

10.1 Produit

```
bash
cp .env.example .env
docker compose up --build
```

Ouvrir **<http://localhost:8080>**. L'API se trouve sur **<http://localhost:8000>** et le document OpenAPI sur **<http://localhost:8000/docs>**.

10.2 Vérification

```
bash
make check
npm --prefix frontend exec playwright install chromium
make test-e2e
make test-real-images
make test-e2e-real
make test-release-persistence
```

10.3 Inférence en ligne de commande

```
bash
cd backend
uv run python inference.py image-1.png image-2.tif --output-dir artifacts/demo
```

10.4 Vue versionnée des benchmarks

```
bash
make benchmark-summary
```

make check vérifie que le résumé frontend généré correspond exactement aux trois rapports JSON verrouillés. Les jeux bruts restent hors de Git et sont acquis ou vérifiés par les manifestes et scripts documentés dans [data/README.md](#).

11. Outils d'IA, bibliothèques et licences

OpenAI Codex et Anthropic Claude Code ont contribué au code, aux tests, à la documentation, aux contre-revues et à la revue de littérature sous contrôle humain. Chaque métrique rapportée provient d'un script ou d'un rapport versionné ; la prose générée n'est pas présentée comme preuve expérimentale. Le produit ne dépend d'aucun LLM, modèle hébergé ou API commerciale.

La déclaration canonique, incluant μ SAM, MobileNetV3, les jeux de données et les bibliothèques principales, est disponible dans [docs/declaration-ia-et-licences.md](#).

Licence du code : Apache-2.0, consignée dans le fichier **LICENSE** à la racine du dépôt.

Bundle modèle : non distribué dans cette soumission ; toute publication future exige une décision de licence séparée et un bundle verrouillé par hash.

12. Conclusion

OrganChip Insight montre qu'une plateforme utile d'imagerie d'organes sur puce ne se définit pas par un score unique. Elle se définit par un chemin complet depuis une entrée validée jusqu'à des preuves inspectables et exportables, avec provenance et limites préservées. Le workflow adaptatif est rapide, local et disponible ; une segmentation externe plus forte mais coûteuse reste un benchmark ; et un classifieur sensible aux raccourcis ne peut pas prendre de décision automatique. La plateforme est donc techniquement assez complète pour être démontrée, tout en restant explicite sur les validations que les futures données devront apporter.

Références

- 1 Movčana et al. "Organ-On-A-Chip (OOC) Image Dataset for Machine Learning and Tissue Model Evaluation." *Data* 9(2):28, 2024.
- 2 Ljosa, Sokolnicki et Carpenter. "Annotated high-throughput microscopy image sets for validation." *Nature Methods* 9:637, 2012.
- 3 Archit et al. "Segment Anything for Microscopy." *Nature Methods*, 2025.
- 4 Archit et Pape. "Revisiting foundation models for cell instance segmentation." MIDL, 2026.
- 5 Howard et al. "Searching for MobileNetV3." ICCV, 2019.